- Projet -

Machine Learning

CGMacros : a scientific dataset for personalized nutrition and diet monitoring

crédit : Getty Images

- E4 Bio -

Palliere Raphael & Bouny Mathieu
palliere.raphael@icloud.com
bouny.mathieu@gmail.com

Table des matières

Préambule **2**
Choix et Justification du Dataset **3**
Analyse exploratoire **5**
1. Compréhension et Réflexion autour du dataset 5
2. Identification des difficultés 10
Protocole et Stratégie de validation **14**
1. Enjeu à relever 14
2. Stratégie de partitionnement 14
3. Modèle de référence (baseline) 15
4. Métriques d'évaluation 15
5. Stratégie de sélection des modèles 16
6. Chaîne de traitement expérimental 17
7. Robustesse 17
Comparaison et Analyse **18**
1. Performances 18
2. Analyse Comparative 19
3. Robustesse 20
4. Analyse qualitatives des erreurs 20
6. ANalyse des probabilités/seuils - Classifications 21
Interprétation et Explicabilité des modèles **22**
1. Variables les plus influentes 22
2. Cohérence 23
3. Interprétation 23
Discussion et Limites **24**
1. Synthèse 24
2. Limites 24
a. Limites du Protocole expérimental 24
b. Limites du dataset 24
3. Généralisation et robustesse externe 24
4. Perspectives d'amélioration 26

Préambule

La maîtrise de la glycémie postprandiale est un enjeu clinique majeur pour la prévention et la gestion des troubles métaboliques. L'objectif global de ce projet est de développer un modèle de Machine Learning capable de prédire la réponse glycémique, 60 minutes après le début d'un repas. Pour ce faire, nous analyserons l'interaction complexe entre l'historique glycémique continu (CGM), la composition des repas, l'activité physique et le profil clinique individuel, au sein d'une population regroupant des sujets sains, prédiabétiques et atteints de diabète de type 2.

L'accès à des données médicales de qualité exige une rigueur éthique stricte, notre démarche a débuté par l'obtention des accréditations du CITI Program pour la recherche sur des sujets humains. Cette certification nous a permis d'accéder à plus de base de données sur PhysioNet. C'est sur cette plateforme que nous avons sélectionné le jeu de données *CGMacros*.

Dans ce rapport, notre démarche suit des phases clés. Nous débuterons par une analyse exploratoire approfondie avec, à cela, une phase de préparation des données. Cette étape nous permettra d'appréhender les dynamiques temporelles du jeu de données, de gérer les valeurs manquantes et de concevoir des variables pertinentes (feature). Afin de garantir la fiabilité de nos futurs résultats, nous définirons ensuite un protocole d'évaluation robuste.

Ensuite, nous procéderons à la modélisation d'algorithmes adéquate à la situation. Notre approche se basera sur : une évaluation en régression pour prédire la valeur glycémique exacte, et une classification visant à catégoriser l'état du patient (hypoglycémie, normoglycémie ou hyperglycémie). Mise à part la performance prédictive, nous accorderons une importance à l'interprétabilité clinique de nos modèles. Nous chercherons à identifier les variables les plus influentes et à décrypter les décisions algorithmiques. Nous voulons, à terme, confronter ces résultats à l'expérience de patients experts. Enfin, notre étude se conclura par une discussion critique sur la réalisation de votre projet sur ce jeu de données.

Choix et Justification du Dataset

Après une analyse rigoureuse des options disponibles sur PhysioNet, notre choix s'est porté sur le jeu de données *CGMacros*. *CGMacros* comprend **45 participants** suivis en conditions de vie réelle pendant 10 jours consécutifs : 15 sujets sains, 16 sujets prédiabétiques et 14 sujets atteints de diabète de type 2. Pour les observations, le jeu de données contient 45 fichiers principaux, un par participant, avec des mesures longitudinales de glycémie et d'activité. Le protocole repose sur deux capteurs CGM, qui vont prendre un échantillonnage toutes les 5 minutes pour l'un et 15 minutes pour l'autre. Si nous raisonnons sur 5 minutes cela nous fera 45 × 10 jours × 288 mesures/jour = 129 600 points de

glycémie en tout. Cela nous permettra de générer plusieurs milliers d'exemples autour des repas.

Au-delà du volume, c'est la multimodalité des variables proposées par *CGMacros* qui justifie son exploitation. Le jeu de données ne se limite pas à la seule dynamique glycémique, mais englobe l'ensemble du contexte physiologique et comportemental du patient. Il intègre la composition nutritionnelle détaillée de chaque repas, incluant les calories totales, les glucides, les protéines, les lipides, les fibres ainsi que la typologie du repas. À cela s'ajoutent les données d'activité physique mesurées par des dispositifs Fitbit, telles que les équivalents métaboliques (METs) et la fréquence cardiaque. Enfin, ces variables sont contextualisées par des différents types de variables (âge, sexe, IMC) et des marqueurs biologiques essentiels (HbA1c, glycémie à jeun, insuline, bilan lipidique), permettant d'ancrer nos prédictions dans une réalité clinique tangible.

D'un point de vue méthodologique, l'utilisation de ce jeu de données soulève des défis stimulants que nous avons pleinement intégrés à notre conception. La taille de la base (45 patients) peut paraître restreinte au premier abord. En revanche, en isolant des fenêtres temporelles autour de chaque prise alimentaire, nous pouvons extraire plusieurs milliers d'événements "repas". Nous transformons ainsi un échantillon de patients limité en un jeu de données contenant plusieurs milliers de données. Par ailleurs, nous sommes conscients du risque majeur de corrélation intra-patient inhérent à ce type de données. Pour éviter toute fuite de données (data leakage), notre stratégie est de séparer les jeux d'entraînement et de test par patient, et non de manière aléatoire. La gestion des données manquantes fera également l'objet d'un traitement spécifique adapté aux séries temporelles.

Enfin, l'exploitation de *CGMacros* s'inscrit dans une perspective d'application clinique forte, axée sur la médecine personnalisée et préventive. Initialement, notre première approche de ce JDD nous a mené sur deux pistes de travail : prédire une valeur continue (donc via régression) ou bien classer le statut métabolique postprandial (hypoglycémie, normo glycémie, hyperglycémie). Face à ces deux propositions, il y a un risque de dispersion. Nous avons donc énuméré les avantages et les contraintes pour faire le choix le plus logique :

- L'approche par régression avec application de seuils cliniques a posteriori :
  Cette méthode consiste à entraîner un modèle (par exemple des arbres de régression) pour prédire la valeur exacte de la glycémie à t+15, t+30 et t+60 minutes. L'avantage majeur est de conserver toute la richesse de l'information quantitative, permettant de différencier une hyperglycémie légère ou bien sévère par exemple. L'inconvénient principal est l'effet de bord : le modèle cherchant à minimiser l'erreur numérique globale, une infime imprécision près d'un seuil clinique peut entraîner une erreur totale de classification.

- L'approche par classifieur multiclasse dédiée : Cette méthode implique de discréditer la variable continue en trois catégories distinctes (hypo/normo/hyper) avant même l'entraînement du modèle. L'algorithme est alors mathématiquement optimisé pour pénaliser les erreurs de changement de classe, ce qui améliore la précision sur les frontières diagnostiques. En revanche, cette approche induit une perte d'informations sur l'amplitude des variations glycémiques et nécessite la mise en place de techniques complexes pour pallier le déséquilibre naturel des classes (les

événements de normoglycémie étant surreprésentés par rapport aux hypoglycémies).

Analyse exploratoire

1. Compréhension et Réflexion autour du dataset

CGMacros est un ensemble de données contenant des informations multimodales issues de deux glucomètres continus (CGM), des données sur les macronutriments alimentaires, des photographies des aliments et des données sur l'activité physique, ainsi que des données démographiques anonymisées sur les participants, des mesures anthropométriques et des paramètres de santé issus d'analyses sanguines et de profils du microbiome intestinal.

Il regroupe les données de **45 participants** suivis pendant 10 jours consécutifs en conditions de vie réelle, avec trois profils métaboliques :

- 15 sujets sains,
- 16 prédiabétiques
- 14 diabétiques de type 2.

Les deux CGM utilisés sont un Dexcom G6 Pro (échantillonnage toutes les 5 minutes) et un Abbott FreeStyle Libre Pro (toutes les 15 minutes), puis les séries publiées sont interpolées à une résolution d'une minute.

D'un point de vue analytique, ce n'est donc pas un dataset tabulaire classique "une ligne = un patient", mais plutôt un dataset complet sur chaque patient (un tableau pour chaque patient) où l'on regroupe à la fois un niveau patient, un niveau repas, et un niveau série temporelle.

On peut organiser les variables de CGMacros en cinq blocs :

1. **Variables de profil patient :**

Le dataset contient des variables démographiques telles que l'âge, le genre, la race/ethnie, la taille, le poids et le BMI (Body Mass Index). Toutes ces variables sont conservées dans un même et seul tableau pour tous les patients. Toutes ces données de profil sont donc visualisables simultanément.

2. **Variables glycémiques temporelles :**

Le cœur du dataset est constitué des signaux CGM provenant de deux dispositifs. On dispose donc de séries temporelles de glycémie exprimées en mg/dL. Ces données sont comprises dans un fichier excel par patient nommé "*CGMacros-0XX*" avec XX, le numéro du patient.

3. **Variables nutritionnelles liées aux repas :**

Les repas sont documentés par leur composition en glucides, protéines, lipides, fibres et calories totales, ainsi que par leur timing. Le protocole comporte des petits-déjeuners et déjeuners partiellement standardisés pour couvrir des profils nutritionnels variés, tandis que les dîners sont libres. Cette structure est précieuse car elle offre à la fois une partie relativement contrôlée et une partie plus réaliste. A noter que ces données sont dans le même fichier excel que les variables glycémiques temporelles.

4. **Variables d'activité physique :**

Le Fitbit fournit des mesures d'activité, notamment les METs et la fréquence cardiaque. Ces variables sont importantes car la glycémie postprandiale n'est pas déterminée uniquement par le contenu du repas. Logiquement, l'activité physique récente modifie aussi la captation du glucose et la sensibilité à l'insuline. Ces données sont comprises dans le fichier excel : "*gut_health_test.csv*"

5. **Variables microbiote / gut health :**

Le dataset inclut aussi des informations de microbiote, c'est-à-dire l'énumération de la présence ou absence de 1 979 bactéries et des scores digestifs/"gut health" ordonnés. C'est scientifiquement riche, mais méthodologiquement plus délicat, dû au faible nombre de sujets. Ces données sont gardées dans un seul et même fichier .csv : "microbes.csv".

Ce que l'on peut amener juste avec cette première vision c'est la multimodalité des données de CGMacros. On y trouve :

1. des données numériques statiques (âge, BMI, HbA1c),
2. des données temporelles continues (CGM, activité),
3. des données événementielles (repas horodatés),
4. des données compositionnelles (macronutriments),
5. et éventuellement des données à très grande dimension (microbiote).

6. **Modification de bio.csv :**

Nous avons modifié le fichier *bio.csv* afin d'ajouter la colonne *group* afin de classer les patients en 3 catégories distinctes et claires : sain, prédiabètique et diabétique de type 2. Nous avons pu les classer grâce à la valeur *A1c PDL (lab)*, qui nous donne le taux d'hémoglobine glyquée (en pourcentage).

7. **Tableau récapitulatif :**

Nom de la variable	Type de donnée	Description	Explication de la signification
subject	Numérique (entier)	Identifiant unique du participant.	Élément technique indispensable pour grouper les données par individu et éviter la fuite de données (data leakage) lors de la validation croisée.
group	Catégoriel (nominal)	Statut métabolique du patient (healthy, prediabetes, t2d).	Variable cible clinique de base permettant de stratifier la cohorte et d'analyser les différences de réponses physiologiques.
Age	Numérique (entier)	Âge du participant exprimé en années.	Facteur de risque majeur influençant la sensibilité à l'insuline et la régulation métabolique globale.

Gender	Catégoriel (binaire)	Sexe biologique du participant (M/F).	Paramètre influençant la répartition des masses tissulaires et la cinétique métabolique basale.
BMI	Numérique (continu)	Indice de Masse Corporelle (IMC).	Indicateur clinique standardisé de la corpulence, fortement corrélé aux risques d'insulinorésistance.
Body weight	Numérique (continu)	Poids corporel mesuré en livres (lbs).	Mesure anthropométrique brute nécessitant une conversion en kilogrammes pour les standards internationaux.
Height	Numérique (continu)	Taille corporelle mesurée en pouces (inches).	Mesure anthropométrique brute nécessitant une conversion en centimètres.
Self-identify	Catégoriel (nominal)	Ethnie auto-déclarée par le participant.	Variable démographique capturant de potentielles prédispositions génétiques ou habitudes socio-environnementales.
A1c PDL (Lab)	Numérique (continu)	Taux d'hémoglobine glyquée en pourcentage.	Marqueur clinique de référence évaluant l'équilibre glycémique moyen sur les 2 à 3 derniers mois.
Fasting GLU - PDL (Lab)	Numérique (continu)	Glycémie à jeun mesurée en laboratoire (mg/dL).	Évalue la capacité basale de l'organisme à réguler sa glycémie après une nuit complète sans apport calorique.
Insulin	Numérique (continu)	Taux d'insuline sanguin à jeun.	Crucial pour identifier une hyperinsulinémie compensatoire, marqueur précoce de la résistance à l'insuline.
Triglycerides	Numérique (continu)	Concentration de triglycérides sanguins (mg/dL).	Lipides dont l'excès est un marqueur très fort du syndrome métabolique et du risque cardiovasculaire.
Cholesterol	Numérique (continu)	Cholestérol total sanguin (mg/dL).	Mesure globale des lipides circulants utilisée pour évaluer le profil cardiovasculaire de base.
HDL	Numérique (continu)	Lipoprotéines de haute densité (mg/dL).	Souvent appelé "bon cholestérol", il participe à l'élimination du cholestérol en excès dans le sang.
Non HDL	Numérique (continu)	Cholestérol total moins le HDL (mg/dL).	Représente l'ensemble des lipoprotéines athérogènes (qui favorisent les plaques sur les artères).
LDL (Cal)	Numérique (continu)	Lipoprotéines de basse densité calculées (mg/dL).	Le "mauvais” cholestérol, principal responsable du risque de maladies cardiovasculaires associé au diabète.
VLDL (Cal)	Numérique (continu)	Lipoprotéines de très basse densité calculées (mg/dL).	Particules transportant principalement les triglycérides synthétisés par le foie vers les tissus.
Cho/HDL Ratio	Numérique (continu)	Rapport entre le cholestérol total et le HDL.	Indice clinique composite utilisé par les médecins pour affiner l'évaluation du risque cardiovasculaire.

8. Graphes de répartitions :

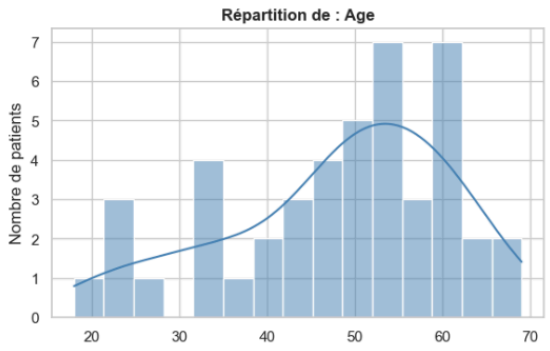
Répartition de : Age
Nombre de patients
0 1 2 3 4 5 6 7
20 30 40 50 60 70

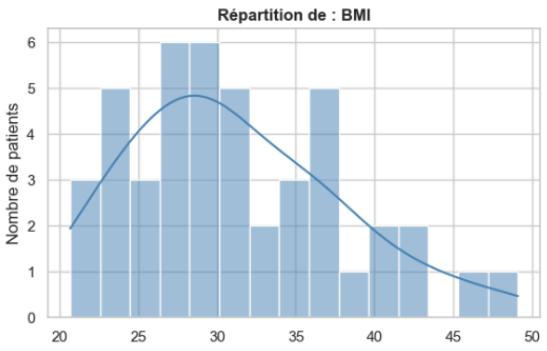
Répartition de : BMI
Nombre de patients
0 1 2 3 4 5 6
20 25 30 35 40 45 50

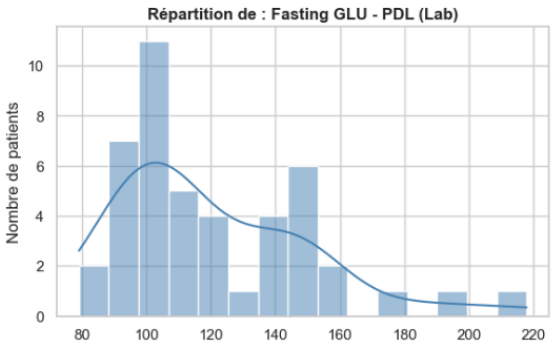
Répartition de : Fasting GLU - PDL (Lab)
Nombre de patients
0 2 4 6 8 10
80 100 120 140 160 180 200 220

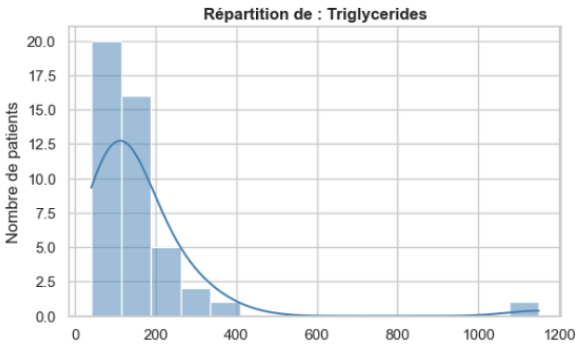
Répartition de : Triglycerides
Nombre de patients
0.0 2.5 5.0 7.5 10.0 12.5 15.0 17.5 20.0
0 200 400 600 800 1000 1200

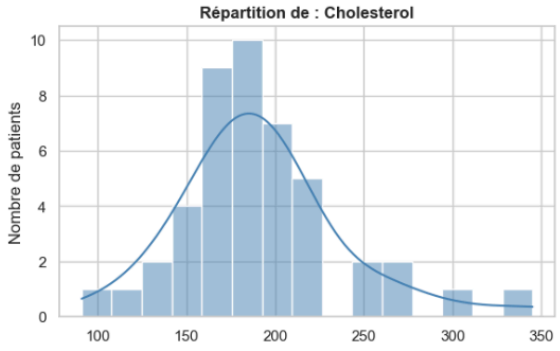
Répartition de : Cholesterol
Nombre de patients
0 2 4 6 8 10
100 150 200 250 300 350

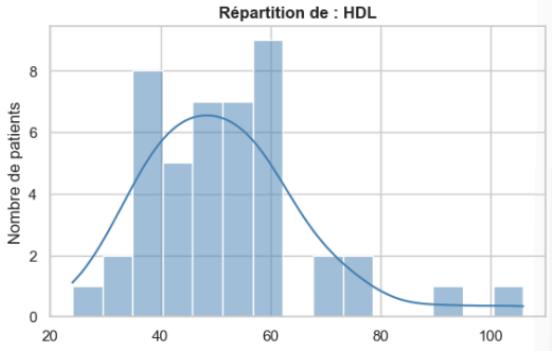
Répartition de : HDL
Nombre de patients
0 2 4 6 8
20 40 60 80 100

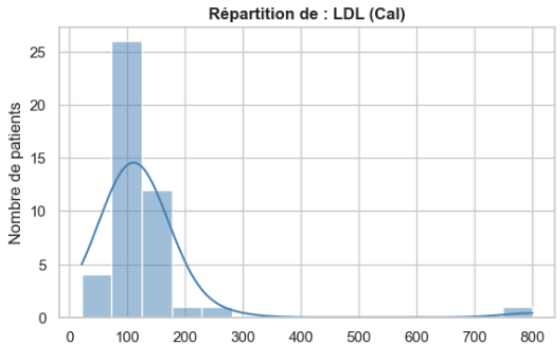
Répartition de : LDL (Cal)
Nombre de patients
0 5 10 15 20 25
0 100 200 300 400 500 600 700 800

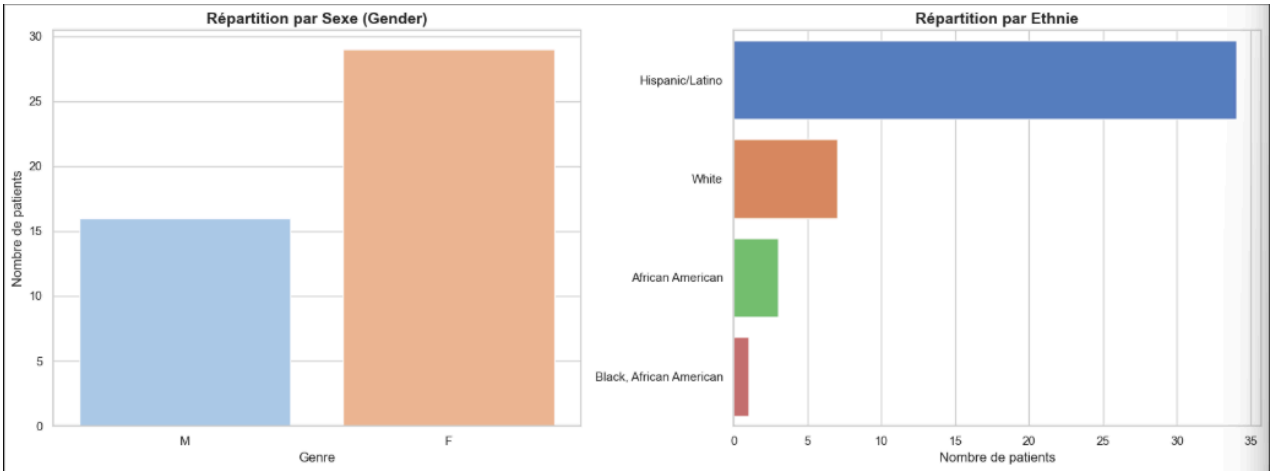

A notre niveau de connaissance et le but de ce projet, nous aurons tout d'abord un gros travail de restructuration des données. Le dataset brut est rempli avec peu de données manquantes, ce qui invite à fabriquer des unités. (Nous avons déjà coder un petit programme pour avoir une colonne dans bio.csv donnant directement la classe du patient : sain/pré-diabètique/diabète de t2.)

En termes de cohérence des unités, GCMacros est vraiment cohérent. Les valeurs de glucose sont exprimées en mg/dL, ce qui est standard en contexte clinique nord-américain.

Le dataset repose sur des horodatages, mais les dates ont été décalées artificiellement pour des raisons de confidentialité. En revanche, il va falloir faire attention au niveau de la forme de la date, qui est du type nord-américain. A adapter au mieux notre code à cette forme si besoin.

Le point de vigilance le plus important concerne l'existence de deux CGM différents. L'analyse des datas nous a permis de voir des écarts systématiques entre les lectures Abbott et Dexcom, avec des niveaux moyens parfois sensiblement différents selon le statut métabolique. On remarque aussi que certains patients n'ont pas de mesure sur les deux CGM. Il y a en revanche toujours le capteur Libre GL (Abbott). Nous allons donc surement nous baser sur celui-là. Il est possible aussi d'introduire explicitement la variable type de capteur pour comparer.

Les macronutriments sont exprimés en grammes, ce qui est cohérent. En revanche, leur interprétation doit être prudente. Deux repas ayant le même nombre de glucides peuvent produire des réponses glycémiques très différentes selon la part de fibres, de lipides, l'ordre alimentaire, ou le contexte physiologique du sujet. Donc même si les unités sont propres, la relation clinique n'est pas linéaire.

Cliniquement, CGMacros raconte déjà quelque chose d'important avant même toute modélisation : la réponse glycémique est multifactorielle et fortement personnalisée. L'étude de validation rapporte bien une augmentation nette de la glycémie moyenne entre les groupes sains, prédiabétiques et T2D. Ainsi que des différences de temps passé en

hyperglycémie inter-groupes. Cela confirme que le signal CGM porte bien une information clinique discriminante sur le statut métabolique.

Le dataset n'est donc pas seulement sur le diabète mais plutôt sur une évolution de la glycémie sur un métabolisme individuel, appartenant expressément à un groupe.

2. Identification des difficultés

i. Variables problématiques

Nous avons deux variables qui nous semblent problématiques à première vue, la première étant le capteur *DEXCOM GL* qui présente des données manquantes, et qui à parfois des variations contradictoires avec l'autre capteur *Libre GL* (voir fichier *CGMacros-003* après le launch). La seconde variable problématique est la variable de l'ethnie, nous savons que dans certains problèmes de santé peuvent êtres liés à l'ethnie.

Afin de régler ces problèmes nous avons fait le choix de ne pas utiliser les données du capteur DEXOM GL, ce qui permet de n'avoir que le capteur LIBRE qui ne présente pas de problème de données manquantes. Pour la variable qui concerne l'ethnie, nous nous sommes renseignés sur les liens suivant :

- https://pubmed.ncbi.nlm.nih.gov/41330055/
- https://pubmed.ncbi.nlm.nih.gov/36273116/

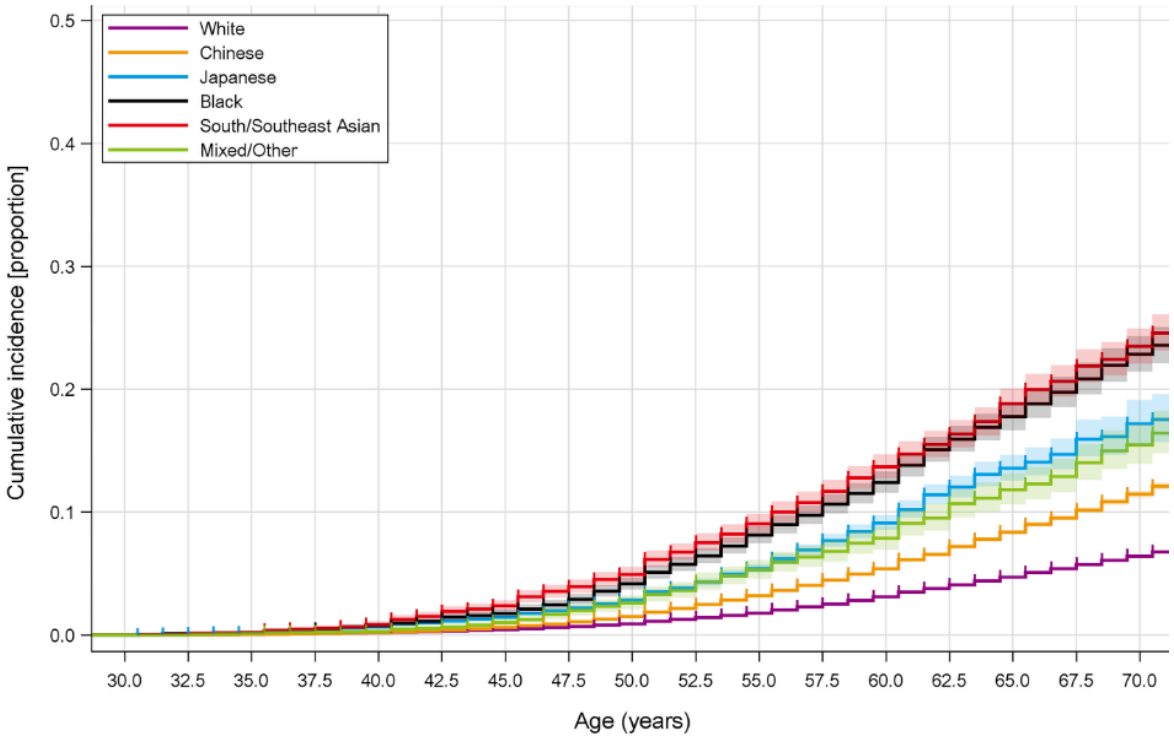

Cette courbe illustre l'incidence cumulative entre 30 et 70 ans selon les groupes raciaux et ethniques. Nous observons qu'à 70 ans, près d'une femme sur quatre (25%) d'origine sud-asiatique/sud-est asiatique ou noire était atteinte de diabète, contre seulement 7% des femmes blanches.
La moyenne d'âge des patients étant de + 50 ans, avec une répartition allant jusqu'à 70 ans, et sachant que nous avons plus de femmes que d'hommes. Nous concluons alors que cette variable était cohérente et utile pour la suite de notre projet.

Cependant, la prise en compte de cette variable complique énormément les calculs. Nous allons donc commencer par ne pas prendre l'ethnie en compte, cette décision n'est pas définitive et nous pourrons l'intégrer à nos calculs par la suite.

ii. Déséquilibres

Dans nos données nous avons plusieurs déséquilibres, mais il est important de dire que nous avons une répartitions quasi parfaite entre les patients sains, prédiabétiques, et diabétiques de type 2 :

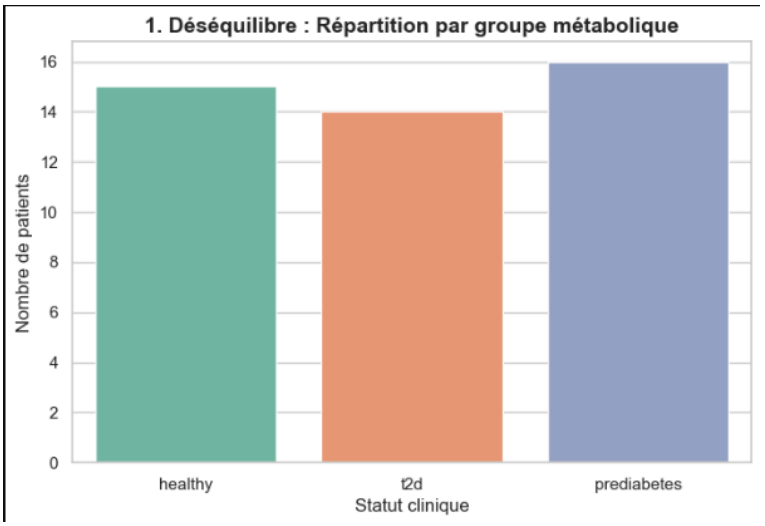

Cependant, comme nous l'avons vu précédemment, certaines variables comme l'ethnie ou le genre peuvent entraîner des interprétations supplémentaires. Et dans notre jeu de données, nous avons justement des déséquilibres dans ces classes la :

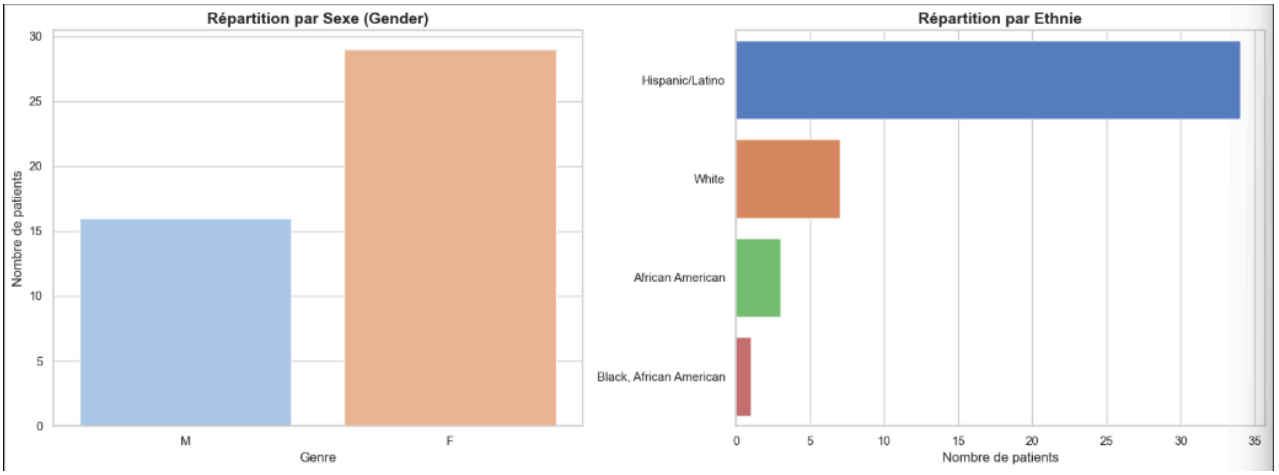

Nous avons donc près de 2x plus de femmes que d'hommes et une énorme majorité de patients hispaniques / latinos. Il faudra donc bien prendre en compte ces deux variables qui peuvent engendrer quelques difficultés.

iii. Valeurs aberrantes

Afin d'identifier de potentielles valeurs aberrantes nous avons procédé à une analyse des données et une modélisation afin d'afficher nos recherches plus facilement, et les rendre visuelles :

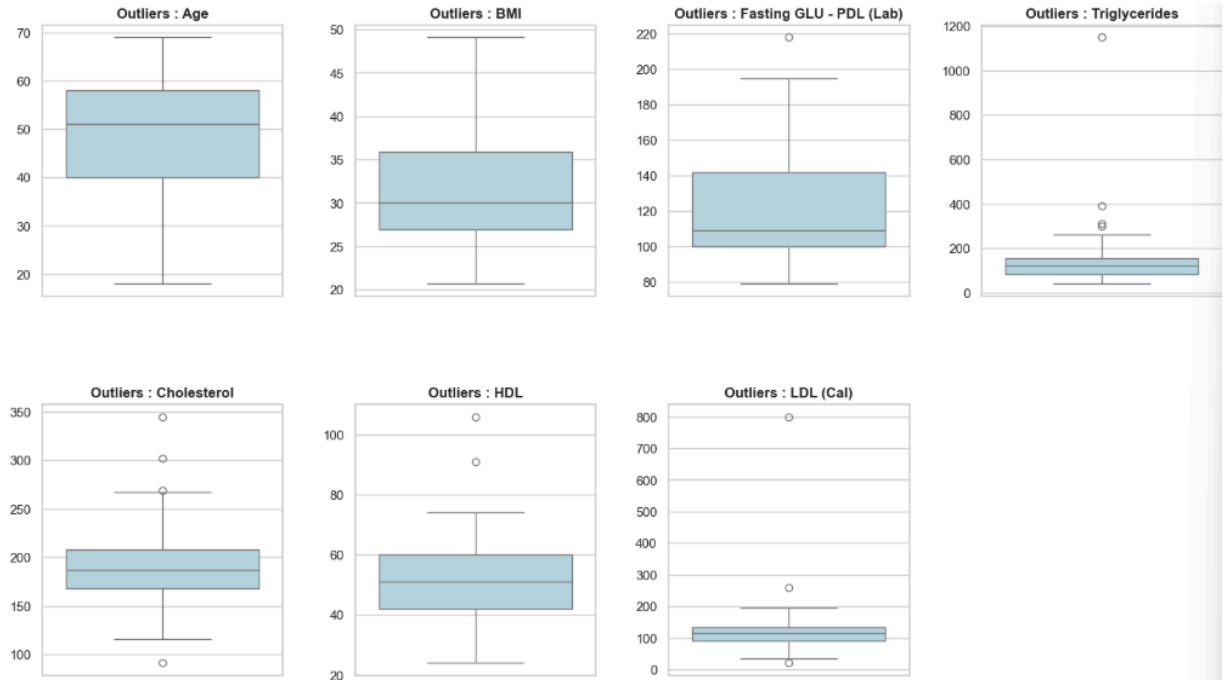

Ici nous observons assez facilement que certaines valeurs paraissent complètement aberrantes, nous nous sommes alors penché plus profondément sur nos données afin d'identifier la source de ces valeurs aberrantes.
Le coupable est le patient n°12, en effet ce patient est l'unique raison des valeurs aberrantes. Le fait que toutes les valeurs aberrantes viennent de lui nous a fait nous poser

des questions, est-ce vraiment des valeurs aberrantes ? ou est-ce qu'il y a une explication médicale logique qui les explique ?

Voilà notre conclusion : les valeurs ne sont PAS aberrantes. En effet, le patient présente sans doute des problèmes de cœur, nous pouvons l'expliquer par la valeur élevée des valeurs de Triglycéride et LDL notamment. Nous pourrions donc logiquement garder ces valeurs et dire que le problème ne vient pas d'erreur mais d'une autre maladie / problème de santé. Seulement notre projet consiste à prédire une valeur de glycémie, alors garder un patient présentant un problème supplémentaire n'est pas vraiment cohérent. Un problème de cœur est externe au diabète, cela va donc complexifier la situation sans être vraiment utile. Nous avons donc pris la décision de supprimer le patient n°12 de notre étude.

iv. Données manquantes

Comme nous l'avons dit dans la partie des valeurs problématiques, le capteur DEXCOM GL présente de nombreuses données manquantes, et parfois même des données qui paraissent incohérentes en comparaison avec le capteur LIBRE.
Nous avons donc pris la décision de supprimer totalement les valeurs données par ce capteur pour notre projet.

v. Redondances & Corrélations

Après avoir analysé nos données et le patient n°12, présentant un problème de cœur, nous avions anticipé certaines corrélations logiques. En effet, les variables Triglycéride et LDL(cal) seront forcément corrélées, car elles représentent deux notions très corrélées. Malgré une forte corrélation, nous considérons donc que supprimer une des deux variables serait complètement incohérent.

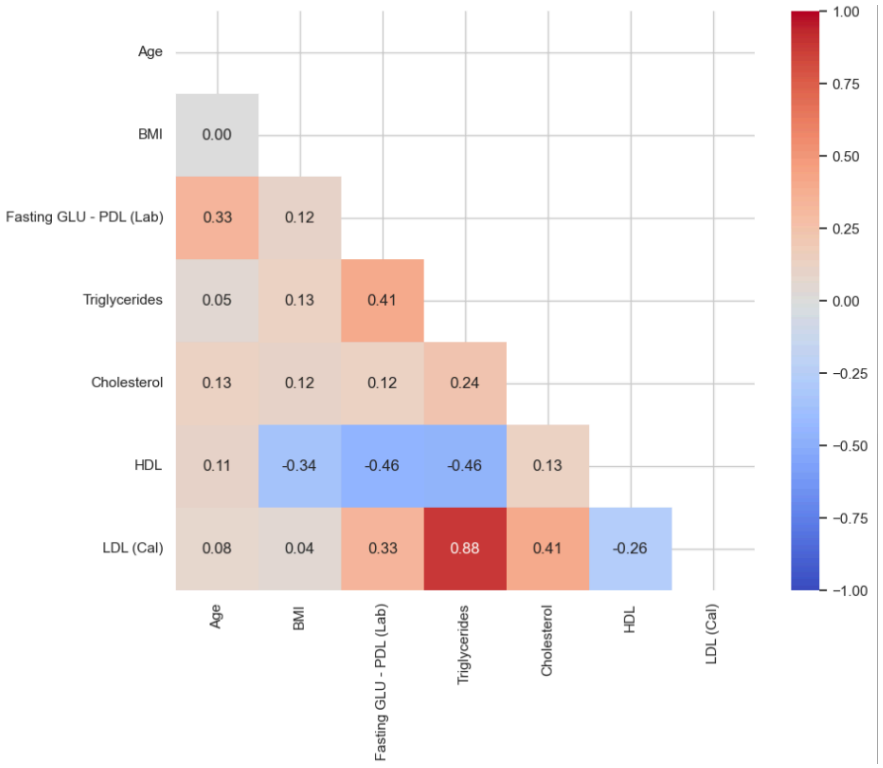

Protocole et Stratégie de validation

1. Enjeu à relever

La conception d'un protocole de validation sur CGMacros est rendue particulièrement difficile par la nature même du jeu de données. En effet, il s'agit d'un dataset longitudinal où les observations ne sont pas indépendantes au sens statistique du terme. C'est-à-dire que chaque patient crée à lui-seul, plusieurs dizaines de fenêtres de temps autour de ses repas. Cela crée une forte corrélation intra-individuelle. En effet, lors de la construction du pipeline de fenêtrage (*meal_window_builder.py*), nous avons transformé les 45 patients en environ 1 700 repas (on compte 3 repas par jour, puis souvent des snacks, pris autour des repas). Cette richesse est une force pour l'entraînement, mais elle dissimule un risque méthodologique majeur, celui d' ignorer cette structure en procédant à un découpage aléatoire des données. Cela constituerait une fuite d'information (data leakage).
L'enjeu central est donc de mesurer la capacité du modèle à prédire la réponse glycémique postprandiale d'un patient qu'il n'a jamais vu. C'est cette question, et seulement elle, qui a une valeur clinique réelle.

Un second enjeu, identifié lors de l'exploration des données brutes, concerne la **qualité et la complétude du signal CGM**. L'analyse du fichier *CGMacros-001.csv* a révélé que certaines fenêtres pré-repas peuvent contenir des valeurs manquantes (NaN), notamment en début ou fin de session de port du capteur. Notre pipeline impose un seuil minimum de 30 points valides sur les 60 minutes pré-repas pour qu'une fenêtre soit retenue, ce qui constitue une décision de filtrage explicite à documenter et justifier dans l'analyse des résultats. Elle est normalement respectée dans tous les cas, mais n'ayant pas vérifié les environs 650 000 lignes, nous avons préféré mettre ce filtre.

Un troisième point de vigilance concerne la **coexistence de deux capteurs CGM** dans le dataset. L'analyse a montré des écarts systématiques entre l'Abbott FreeStyle Libre et le Dexcom G6 selon le statut métabolique du patient, et certains patients ne disposent que du capteur Abbott. Nous avons donc pris la décision de retenir exclusivement le signal Abbott FreeStyle Libre comme source CGM principale, garantissant ainsi l'homogénéité du signal sur l'ensemble des 45 patients.

2. Stratégie de partitionnement

Face à ces contraintes, notre stratégie repose sur un principe unique : le partitionnement se fait exclusivement au niveau du patient**,** jamais au niveau des fenêtres repas individuelles.
Concrètement, nous appliquons une validation croisée de type **GroupKFold** avec *groups = patient_id*, qui garantit qu'aucune fenêtre d'un patient présent dans le jeu de test n'est visible lors de l'entraînement.

3. Modèle de référence (baseline)

Notre première intention était de partir directement sur un Random Forest comme baseline, pour sa robustesse sur les petits datasets et sa capacité à capturer des interactions non linéaires. Nous avons finalement suivi la recommandation de notre encadrant et retenu la régression linéaire comme premier modèle de référence, et ce choix se justifie à plusieurs niveaux.

D'abord, la régression linéaire est le modèle le plus fondamental du machine learning supervisé — elle fixe un plancher de performance interprétable, directement lié aux hypothèses les plus simples : la glycémie postprandiale serait une combinaison linéaire des glucides ingérés, du niveau glycémique de départ, de l'HbA1c, et des autres features. Si ce modèle obtient déjà une performance cliniquement acceptable, cela signifierait que les relations dans les données sont suffisamment linéaires pour ne pas nécessiter de complexité supplémentaire — un résultat scientifiquement intéressant en soi.

4. Métriques d’évaluation

Notre objectif est de comparer les résultats de différents modèles sur la classification et la prédiction, pour cela nous voudrions arriver à un tableau de la forme suivante :

Prédiction temporelle :

Modèle	RMSE t+30	RMSE t+60	RMSE t+90	R^2 t+60
OLS (vraie baseline)	15.14 ± 0.60	31.12 ± 1.82	33.42 ± 1.90	0.510
Ridge	15.27 ± 0.67	31.21 ± 1.80	33.46 ± 1.86	0.507
Arbre de décision	15.21 ± 0.70	31.30 ± 1.89	33.11 ± 2.09	0.501
Réseau de neurone	20.90 ± 0.84	36.25 ± 2.17	36.94 ± 4.58	0.323
Random Forest	19.50 ± ~1	31.0 ± ~2	32.0 ± ~3	0.523
Réseau de neurone	/	/	/	/

Classification à t+60 min :

Modèle	Précision	Rappel	F1 Score
Régression Logistique	0.610 ± 0.06	0.586 ± 0.05	0.506 ± 0.05
Arbres	0.536 ± 0.09	0.523 ± 0.08	0.443 ± 0.08
Random Forest	0.676 ± 0.06	0.513 ± 0.06	0.503 ± 0.06
Réseau de neurone	/	/	/

La métrique RMSE va nous permettre de pénaliser les très grosses erreurs, cela nous permet d'éviter de garder un modèle présentant ce type d'erreur. De plus, elle est exprimée dans les mêmes unités que les cibles variables, donc facilement interprétable. Le seul problème vient du fait qu'une seule valeur aberrante fausse tout.

MAE c'est la moyenne des valeurs absolues des erreurs, donc ca permet de voir l'erreur moyenne sans que les trop gros écarts aient la même importance au pour RMSE. L'interprétabilité de ce marqueur est très facile.

R^2 permet d'avoir la qualité du modèle, nous pouvons aussi nous en servir directement pour voir quel modèle est le meilleur et il permet avec les deux autres métriques d'analyser tout ce que nous voulons voir. Donc il y a une très bonne complémentarité entre nos 3 métriques.

Pour la classification, on commence avec la précision, elle permet de visualiser le nombre de vrais positifs. En complémentarité, le rappel permet de visualiser le nombre de faux négatifs. Or nous savons que les faux négatifs présentent le plus gros point d'attention lorsqu'on travaille sur un modèle, si ce nombre est trop important alors notre modèle n'est pas bon. Le F1 score nous permet ensuite d'avoir une vision sur la moyenne harmonique des 2 métriques précédentes.

5. Stratégie de sélection des modèles

Afin de choisir le meilleur modèle, nous allons tous les tester et les comparer sur les 3 métriques chacun (3 pour la classification et 3 pour la prédiction). Seulement, nous savons que sélectionner le modèle avec les meilleures métriques n'est pas forcément le meilleur choix. Les temps de calculs et d'analyses entrent aussi en compte. Nous allons donc comparer les modèles sur les mêmes données pour ensuite pouvoir les comparer (benchmark).

Mais avant de commencer nous avons procédé à des préparations sur nos données :
=> Ajout d'une colonne group pour chaque patient selon son taux d'HbA1c :

- healthy : <5.7%,
- prediabetes : 5.7 % ≤ HbA1c ≤ 6.4 %,
- et t2d : > 6.4 %

Nous avons alors obtenu *bio_with_group.csv*, ce qui nous permet d'avoir un tableau qui regroupe tous nos patients et les données générales importantes.

Nous avons ensuite construit le dataset de fenêtres de repas, c'est le cœur du pipeline de feature engineering. Pour chaque repas horodaté de chaque patient, ce script extrait :

Nous avons également mené une analyse de sélection de variables en deux étapes. Dans un premier temps, l'importance des variables par réduction d'impureté (indice de Gini) sur l'arbre de décision a permis d'identifier les features les plus discriminantes. Dans un second temps, le Lasso (régularisation L1) a validé de manière indépendante ces conclusions : les deux approches convergent sur les mêmes variables à écarter : *fat, bio_Age, bio_group_encoded, hour_cos, meal_dinner, meal_lunch*. Cette cohérence inter-modèles renforce la robustesse de notre sélection.

Nous avons également testé un pipeline Lasso→Random Forest, où le Lasso sélectionne les features pertinentes avant d'entraîner le RF uniquement dessus. Les résultats montrent que ce pipeline est légèrement moins performant à t+30 et t+60 min, mais s'améliore à t+90 min. Nous discutons de ce résultat dans la section Discussion.

6. Chaîne de traitement expérimental

1. Consolidation du Dataset (Ingénierie des données)

- On récupère les données via CGMacros
- Capture du signal CGM 60 minutes avant le repas (t-60 à t-1) et jusqu'à 90 minutes après
- Intégration des biomarqueurs cliniques, des caractéristiques nutritionnelles et des statistiques agrégées (moyenne, écart-type, min/max)

2. Prétraitement et Sélection de Variables

- On isole les données depré-repas pour le calcul des statistiques afin d'éviter toute fuite d'information avec les données post-repas
- On utilise la régression Lasso et les coefficients de Gini pour filtrer les variables non-significatives (ex: lipides, âge, glycémie à jeun)

3. Évaluation de la Baseline (Modèles Linéaires)

- Modèles testés : OLS (Moindres Carrés Ordinaires), Ridge et Lasso.
- Les performances sont quasiment identiques à t+60 (RMSE ~31 mg/dL), ce qui veut dire que la régularisation simple n'apporte pas de gain directement sur ce jeu de données

4. Analyse de la Complexité (Modèles Non-Linéaires)

- Random Forest : elle est légèrement supérieure à t+90, la corrélation temporelle initiale fait que le random forest n'est pas significativement meilleur que la régression, en raison de sa complexité supplémentaire
- Pipeline Lasso → RF : nous observons une évolution de l'importance des variables au cours du temps, les facteurs influents à t+30 sont différents de ceux à t+90

5. Validation Clinique et Seuils d'Erreur

- Performance vs Seuil ISO : Seule la prédiction à t+30 est proche des standards cliniques (ISO 15197), la difficulté de prédiction augmente de manière exponentielle avec le temps

7. Robustesse

Nous avons pris un cas de contrôle qui peut poser questions sur la prédiction Random Forest :

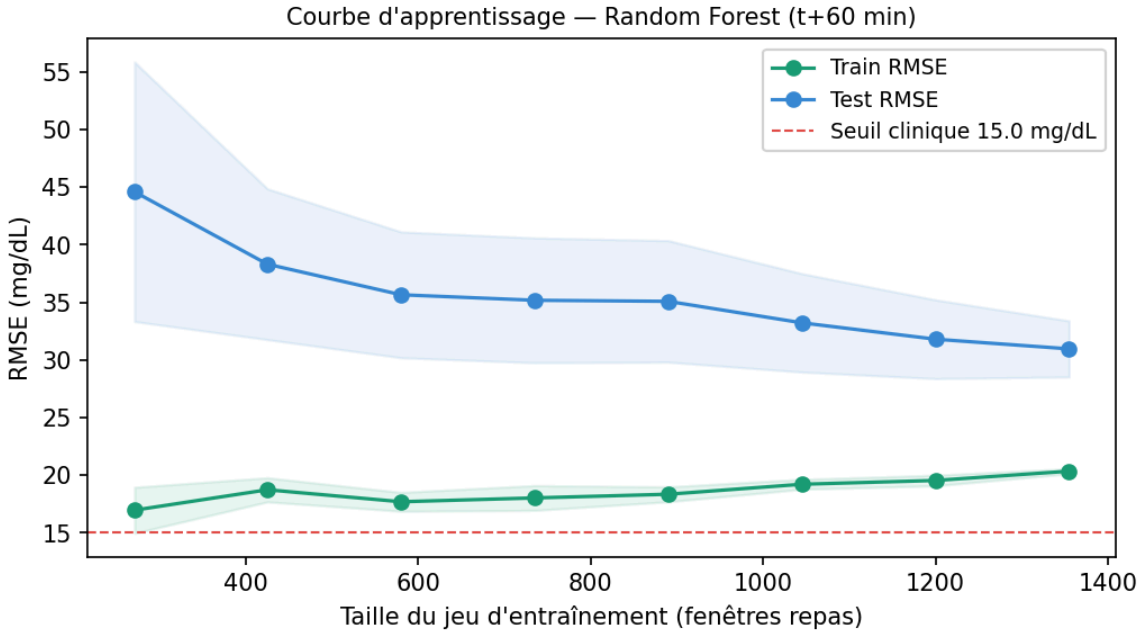

La courbe d'apprentissage du Random Forest à t+60 min montre un écart important et stable entre le RMSE d'entraînement (~15–20 mg/dL) et le RMSE de test (~30–31 mg/dL), quelle que soit la taille du jeu d'entraînement. Cet écart signe un problème de variance plutôt que de biais. En effet, le modèle apprend des patterns spécifiques à chaque patient plutôt que des règles généralisables. On peut l'expliquer à la petite taille de patients (45 patients). Augmenter le nombre de fenêtres repas par patient n'améliore pas la généralisation si la diversité inter-patients reste limitée.

Les écart-types élevés des métriques inter-folds confirment cette instabilité : le R^2 à t+60 min varie de 0.05 à 0.60 selon les patients en test. Cela indique bien que certains profils métaboliques sont bien prédits et d'autres très mal. Cela suggère que la réponse glycémique de certains patients est plus difficile à prédire avec nos features actuelles. Probablement que des patients ont une réponse liée à des facteurs non mesurés (stress, sommeil, microbiome).

Comparaison et Analyse

1. Performances

L'ensemble des modèles testés dépasse le seuil clinique ISO 15197 de 15 mg/dL dès t+60 min, ce qui constitue la limite principale de ce travail. Seule la régression linéaire (OLS/Ridge) parvient à s'en approcher à t+30 min (RMSE ~15.1-15.3 mg/dL), confirmant que la prédiction à court terme est faisable avec des modèles simples.

L'observation la plus notable est que **la régularisation n'apporte pas de gain mesurable** : OLS, Ridge et Lasso affichent des performances quasi-identiques sur les trois horizons (écarts < 0.2 mg/dL de RMSE). Ce résultat indique que les features ne sont pas suffisamment colinéaires pour que la pénalisation change les prédictions de façon significative — ou que le dataset est trop petit pour que cet effet soit détectable.

RMSE	R^2	MAE
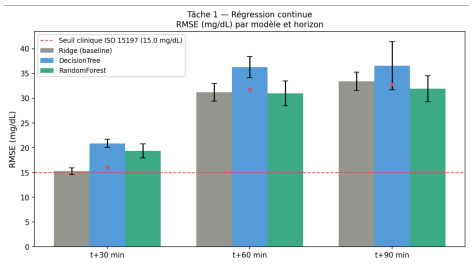	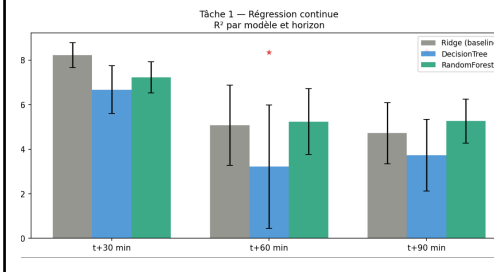	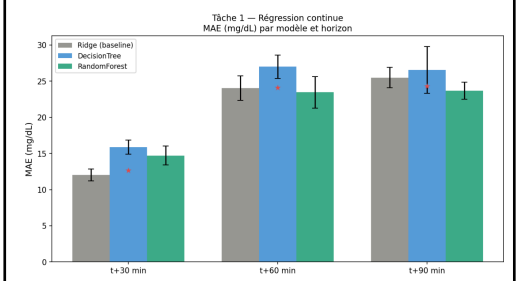

Légende :

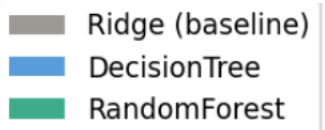

2. Analyse Comparative

Le résultat le plus intéressant de cette comparaison est le changement de meilleur modèle selon l'horizon de prédiction. À t+30 min, la régression linéaire (OLS) domine avec un R^2 de 0.82. La relation est quasi-linéaire car la glycémie n'a pas encore significativement évolué depuis le repas. À t+60 et t+90 min, le Random Forest passe légèrement devant au niveau des résultats (R^2 ~0.52 vs ~0.51 pour Ridge). Les résultats reflètent l'apparition progressive de non-linéarités, de nombreux nouveaux facteurs entrent alors en jeu : la digestion en cours, la réponse insulinique, et les interactions entre macronutriments mais aussi le profil métabolique individuel deviennent des facteurs dominants que les modèles

linéaires ne capturent pas. On peut aussi penser à comment la patient à manger (rapidement sans mâcher, lentement et avec un bon temps de repas).

L'arbre de décision tout seul, reste le moins performant sur les trois horizons, avec un R^2 de seulement 0.32 à t+60 min. Cela s'explique par sa faible capacité de généralisation sur 45 patients avec un seul arbre. Les feuilles prédisent la moyenne de sous-groupes trop étroits pour être représentatifs.

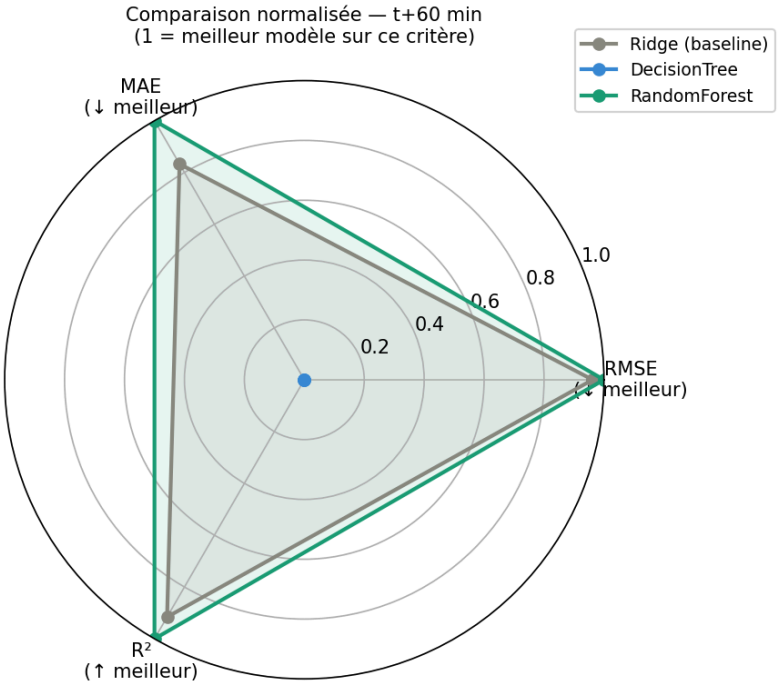

3. Robustesse

Les barres d'erreur élevées sur tous les graphiques de comparaison (écart-types de 1 à 5 mg/dL selon le modèle et l'horizon) témoignent d'une forte variabilité inter-folds. Cette instabilité n'est pas selon nous, un problème de contextualisation du problème, elle reflète la diversité réelle des profils glycémiques entre patients. Certains patients (probablement les sujets sains à glycémie stable) sont bien prédits, d'autres (probablement les diabétiques de Type 2 avec une réponse plus erratique) beaucoup moins. Sans plus de patients, cette variabilité est structurellement irréductible.

4. Analyse qualitatives des erreurs

L'analyse des scatter plots révèle deux types d'erreurs systématiques. Premièrement, une compression vers la moyenne à t+60 et t+90 min : les modèles

sous-estiment les glycémies très élevées (>200 mg/dL) et sur-estiment les glycémies très basses (<80 mg/dL). Ce phénomène est classique dans les problèmes de régression sur données hétérogènes : le modèle apprend la tendance centrale mais manque les extrêmes. Or ce sont précisément les extrêmes (hypoglycémies, hyperglycémies sévères) qui ont le plus d'importance clinique.

Deuxièmement, les scatter plots à t+60 et t+90 min montrent une dispersion en paliers horizontaux sur l'arbre de décision. C'est un signe que le modèle ne prédit que les moyennes de ses feuilles et il n'y aucune continuité entre les prédictions.

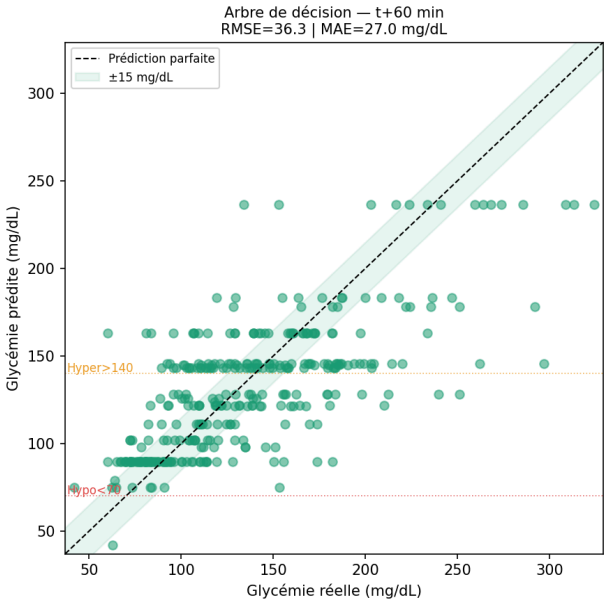

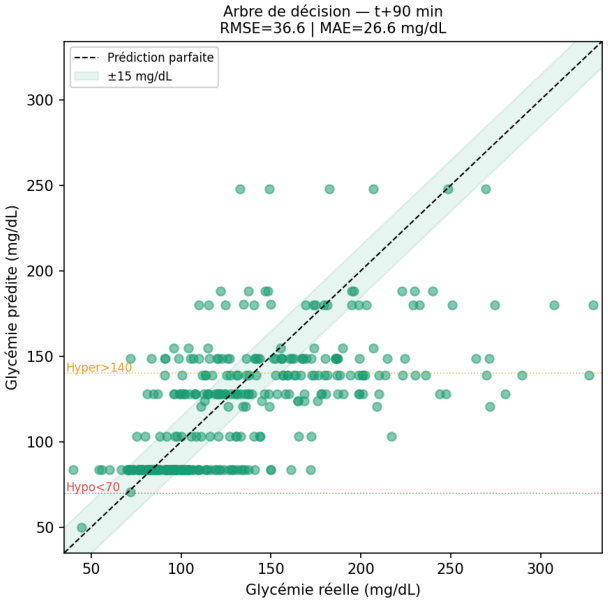

6. ANalyse des probabilités/seuils - Classifications

La deuxième partie de notre projet, en passant de prédiction à de la classification (tâche 2) apporte un éclairage complémentaire. Le F1 score à t+60 min reste moyen pour tous les modèles :

- 0.506 pour la régression logistique,
- 0.503 pour le Random Forest,
- 0.443 pour l'arbre de décision.

Ces valeurs reflètent le déséquilibre naturel des classes : la classe *normal* est sur-représentée dans le dataset (la majorité des repas des sujets sains produisent une glycémie normale), ce qui tire les scores vers le bas sur les classes minoritaires.

Le résultat le plus préoccupant cliniquement est le score de Recall à t+60 min :

- 0.586 pour la régression logistique,
- 0.513 pour le Random Forest.

Cela signifie qu'⅓ de la moitié des événements non-normaux (hypoglycémies et hyperglycémies) sont mal classés. Dans un contexte d'aide à la décision clinique, cette performance est insuffisante pour un usage réel. C'est logique : un outil qui manque une hypoglycémie sur trois n'est pas déployable tel quel.

Un point notable selon nous : la régression logistique obtient le meilleur Rappel (0.586), surpassant le Random Forest (0.513). La séparation linéaire dans l'espace des features, combinée à `class_weight='balanced'`, lui permet de mieux détecter les classes minoritaires que le Random Forest, qui tend à optimiser la précision globale.

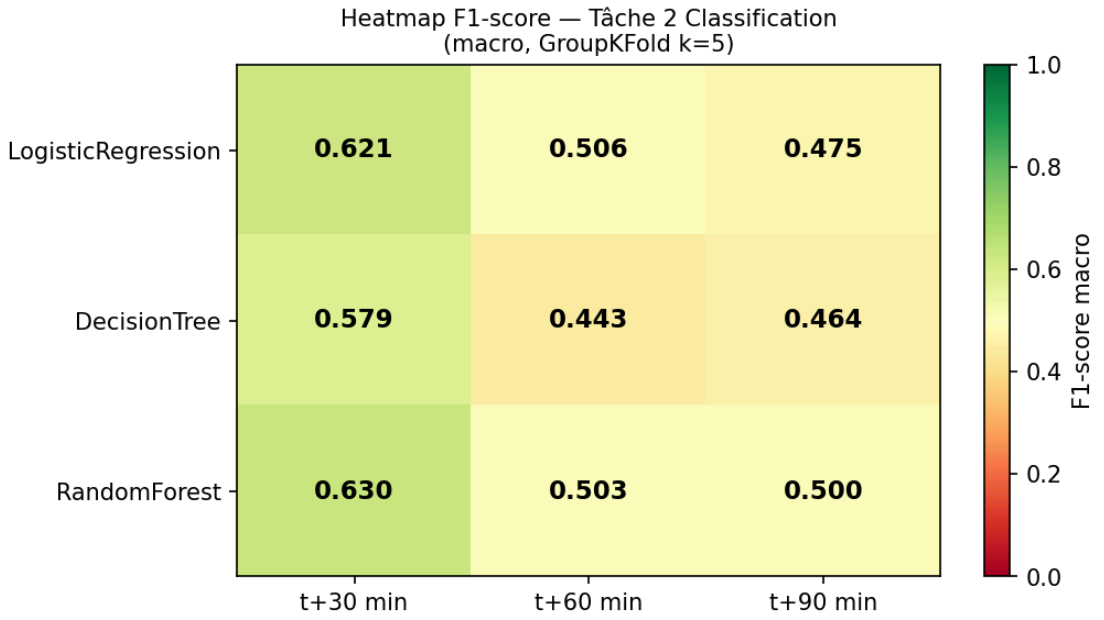

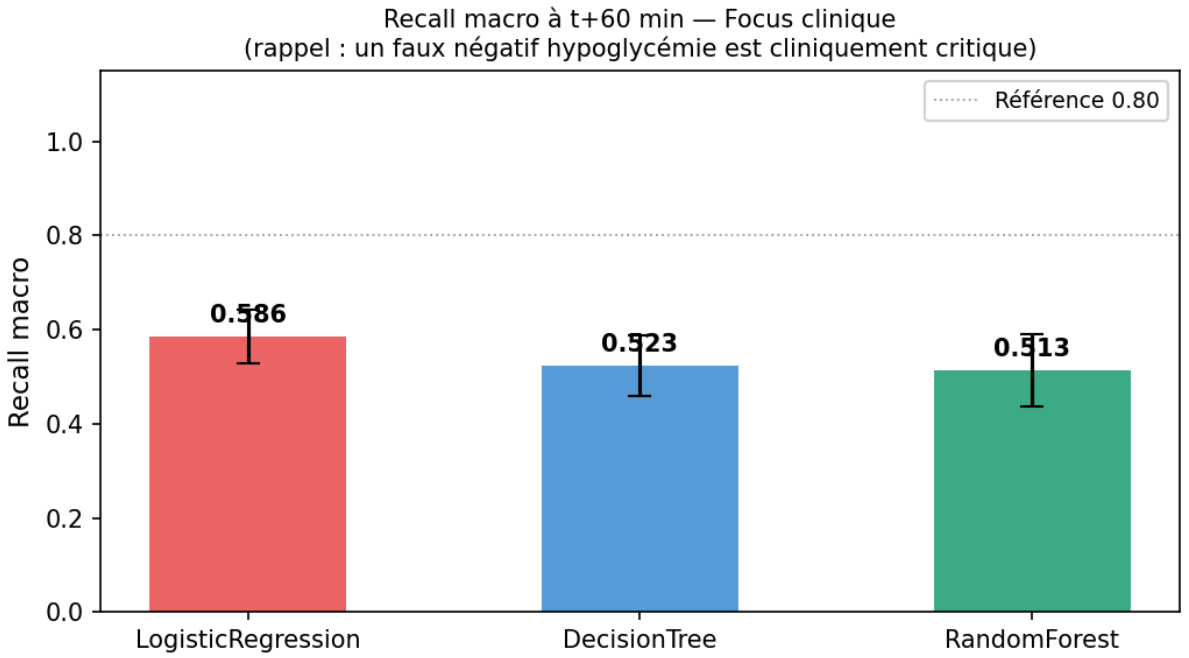

Interprétation et Explicabilité des modèles

1. Variables les plus influentes

L'analyse de l'importance des variables révèle une évolution claire avec l'horizon de prédiction. À t+30 min, *cgm_at_meal* (glycémie au moment du repas) représente ~83% de l'importance dans l'arbre de décision. À t+60 min, la structure change radicalement : *bio_Fasting GLU* (~46%), *cgm_at_meal* (~26%), *meal_breakfast* (~6%), *bio_A1c* (~5%). À t+90 min, le profil clinique prend définitivement le dessus avec *bio_Fasting GLU* à ~47% et *bio_A1c* à ~13%.

L'analyse des coefficients Ridge confirme cette hiérarchie. Le coefficient de *cgm_at_meal* est dominant et positif à tous les horizons (~66–76 après normalisation). La colinéarité entre *cgm_at_meal* et *cgm_pre_mean* est visible : l'OLS leur assigne des coefficients artificiellement opposés (+86 et -126 à t+60), que la Ridge réduit à +66 et -74, et que le Lasso résout en annulant complètement *cgm_pre_mean*.

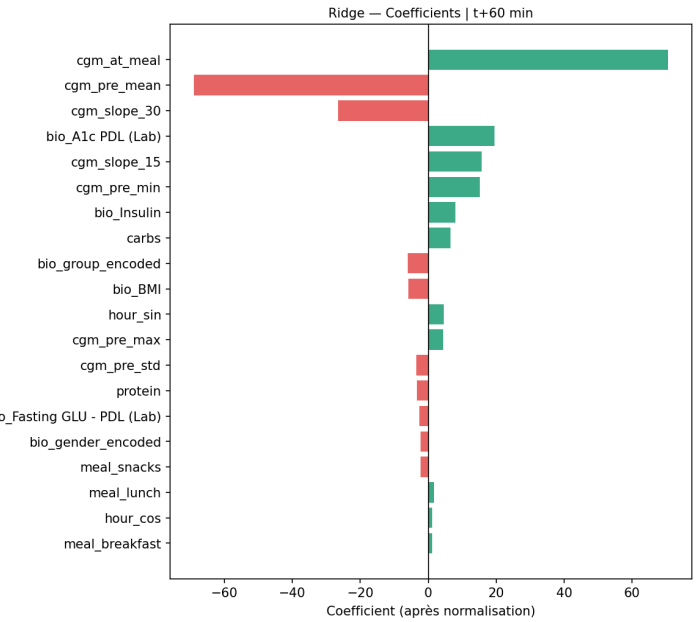

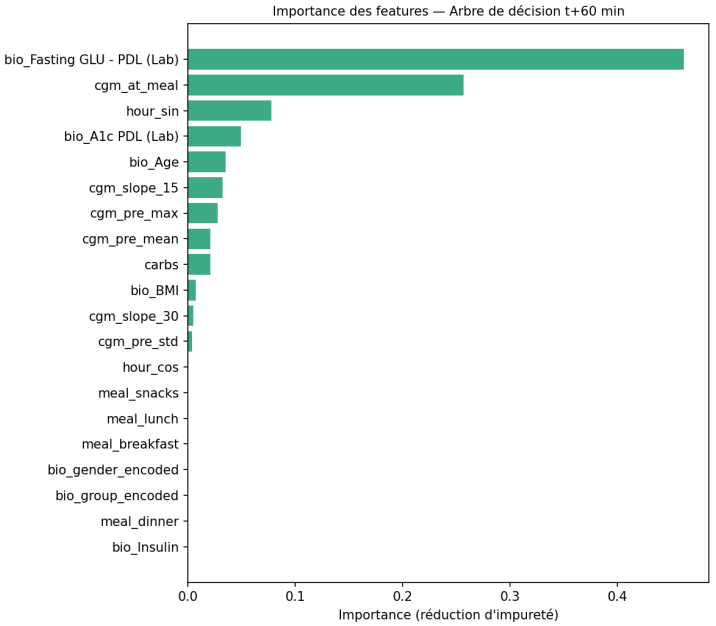

2. Cohérence

Un résultat particulièrement solide est la convergence entre deux approches très différentes pour la sélection de variables. Sur les conseils de Mr Redjdal, nous avons suivi une certaine pipeline pour tester si cela pouvait amener une robustesse et des scores meilleurs :
L'importance du score de Gini, des arbres de décision et la régularisation L1 du Lasso identifient les mêmes variables comme peu pertinentes : fat, bio_group_encoded, bio_gender_encoded, hour_cos, meal_dinner, meal_lunch. Cette cohérence inter-modèles renforce la robustesse de ces conclusions.
Une nuance importante : *bio_Fasting GLU* est ignoré par le Lasso à t+60 min (coefficient annulé) mais domine dans l'arbre de décision (~46%). Ce n'est pas une contradiction, c'est la conclsuion d'un effet non linéaire. Le Lasso suppose une relation linéaire et donc ne détecte pas l'importance de cette variable. En revanche, l'arbre fait des seuils dessus et capture son effet de rupture (par exemple, un patient avec une glycémie à jeun élevée a un comportement postprandial très différent d'un patient avec une glycémie à jeun normale). C'est précisément ce qui justifie l'usage des modèles à base d'arbres sur ce dataset.

3. Interprétation

Pour cette section, nous allons nous baser sur les règles d'un arbre de décision pour bien comprendre. Prenons l'arbre de décision à t+60 :
1- La première règle de partitionnement est "**bio_Fasting GLU ≤ -0.10"** (après standardisation). Les patients sous ce seuil sont principalement les sujets sains. Ils sont ensuite stratifiés par la valeur de cgm_at_meal.
→ En revanche, les patients au-dessus de ce seuil (pré-diabétiques et DT2) voient leur réponse postprandiale davantage influencée par le type de repas (*meal_breakfast*) et la pente glycémique pré-repas (*cgm_slope_15*).

Cette logique est biologiquement cohérente : chez un patient diabétique avec une glycémie à jeun déjà élevée, un petit-déjeuner riche en glucides produit une réponse glycémique particulièrement importante. L'insulinorésistance matinale (phénomène de "dawn effect") amplifie la réponse postprandiale.

Discussion et Limites

1. Synthèse

Ce projet nous confirme que la prédiction de la réponse glycémique postprandiale est un problème difficile, y compris avec un dataset multimodal de qualité. Aucun des modèles testés n'atteint le seuil clinique ISO 15197 (limite utilisé dans les systèmes de résultat de glycémie immédiate) de 15 mg/dL au-delà de t+30 min.

- Le modèle retenu pour l'horizon principal du projet (t+60 min) est le **Random Forest** (RMSE ~31 mg/dL, R^2 ~0.52), légèrement supérieur aux modèles linéaires sur cet horizon.
- Pour t+30 min, la **régression linéaire simple** reste le meilleur choix (RMSE ~15.1 mg/dL, R^2 ~0.82), sa simplicité étant une force et non une faiblesse.

La tâche de classification produit des résultats moyens (F1 macro ~0.50 à t+60 min) qui, bien que insuffisants pour un usage clinique direct, permettent d'identifier la **régression logistique** comme le meilleur compromis en termes de Recall la métrique cliniquement prioritaire pour la détection des hypoglycémies.

2. Limites

a. Limites du Protocole expérimental

Les hyperparamètres des modèles sur les arbres ont été fixés par nous mêmes et nos choix (max_depth=5 pour l'arbre, max_depth=8, n_estimators=200 pour le RF).
Par faute de temps, nous n'avons pas fait de GridSearch.
Une optimisation par validation croisée imbriquée pourrait améliorer les performances, en particulier du Random Forest. Ce point constitue une limite méthodologique explicitement assumée.

b. Limites du dataset

Nous avons remarqué trois limites structurelles du dataset CGMacros qui méritent d'être discuté dans ce projet :
1. La cohorte de 45 patients est trop réduite pour produire des modèles robustes et généralisables. La variance inter-folds élevée nous le montre bien.
2. Les groupes sélectionnés ne sont pas étudiés dans leur cas sans traitement. Par exemple, dans le cas d'un diabétique de type II, au vu des analyses des jeux de données, la glycémie n'est pas analysée sans traitement. Cela montre une moins bonne différence entre les 3 groupes différents dans ce dataset.
3.Des facteurs potentiellement importants ne sont pas mesurés. Par exemple, la qualité du sommeil de la nuit précédente,le stress physiologique, l'ordre de consommation des aliments au sein du repas, composition précise du microbiome au moment du repas (seule une mesure initiale est disponible).

3. Généralisation et robustesse externe

Les modèles entraînés sur CGMacros ne sont pas directement déployables. Ils nécessitent une validation sur un ensemble de patients externes, de composition différente (autre ethnicité, autre tranche d'âge) avant toute utilisation clinique.

4. Perspectives d’amélioration

Plusieurs pistes pourraient améliorer significativement les résultats.
Tout d'abord, l'augmentation de la cohorte (50–100 patients supplémentaires) serait la plus impactante. L'intégration des données de microbiome comme features patient (après réduction dimensionnelle type PCA) ouvrirait une piste cliniquement riche mais méthodologiquement complexe sur 45 sujets. Elles sont dans le jeu de données CGMacros. Mais nous passons dans un projet avec une dimension totalement différente.
Enfin, une architecture de réseau de neurones hybride (GRU sur la séquence CGM + couches denses sur les features statiques) permettrait de capturer les patterns temporels fins que les agrégats statistiques ne résument pas parfaitement.
C’est ce sur quoi nous voulons travailler après le rendu de ce projet : entraîner un système de neurones permettant de prédire à quel moment le patient pourrait rentrer dans une phase d’hyper ou bien d'hypoglycémie.